# 数据集导入

## 1. Neo4j安装

根据课上所学知识我们可以知道 Neo4j是一个高性能的NOSQL图形数据库,它将结构化数据存储在网络上而不是表中。Neo4j也可以被看作是一个高性能的图引擎,该引擎具有成熟数据库的所有特性。在一个图中包含两种基本的数据类型:Nodes(节点)和 Relationships(关系)。Nodes和 Relationships 包含key/value形式的属性。Nodes通过Relationships所定义的关系相连起来,形成关系型网络结构。因此我们本次项目选择采用此方式进行数据集的存储和管理。具体操作流程如下

### 1. 安装java11

Neo4j 4.x以上版本需要java11,与服务器环境不符,因此我们下载安装了java11并更改环境变量来进行安装。

### 2. **安装Neo4j**

我们选择了智慧树上的neo4j-community-4.4.11-windows进行安装,配置环境变量NEO4J\_HOME,并在环境变量Path中添加%NEO4J\_HOME%\bin,至此安装完成。

## 2. 数据集导入

作业要求从COVID-19知识图谱中选取RDF数据集下载,导入知识图谱数据库进行存储管理,要求导入后台数据库的知识图谱规模总量大于一千万条(10 million)三元组,我们选择了String Human PPI数据集,数据集包含了71,787,524个三元组,并进行导入和解析。

#### 1. neosemantics安装

Neo4j 本身是不支持导入 RDF 文件的。但我们可以借助 neosemantics 来进行导入。 neosemantics 简称 n10s , 4.0之前的叫 semantics 。由于我们使用了最新的neo4j-community-4.4.11版本,因此我们下载了最新的4.4.0.2版本的插件,并将其复制 到 neo4j 的 安装目录下的 plugins 文件夹中,在 neo4j/neo4j.conf 文件中添加以下内容:

dbms.unmanaged\_extension\_classes=n10s.endpoint=/rdf

之后进入neo4i浏览器中进行初始化:

```
CALL n10s.graphconfig.init();
```

将数据持久化到Neo4j中的所有方法都有一个模式级的先决条件:这是在带有标签资源的节点的属性URI上存在唯一性约束。如果约束还没有出现,需要在neo4j上运行:

```
CREATE CONSTRAINT n10s_unique_uri ON (r:Resource) ASSERT r.uri IS UNIQUE;
```

否则rdf导入会报错。这个约束的目的是通过URI保证资源的唯一性,并通过将资源添加到索引来加速获取过程。此时大功已经告成了。我们可以导入 RDF文件了。

#### 2. 导入数据

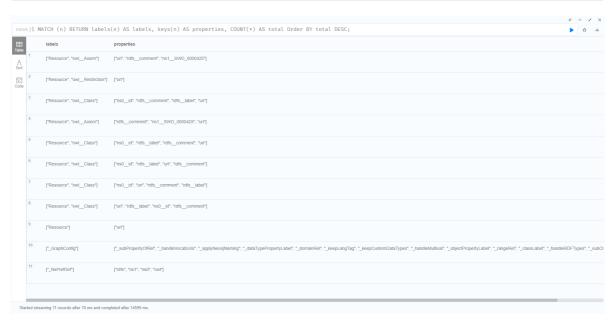
运行:

```
call n10s.rdf.import.fetch("file://%NEO4J_HOME%\import\string-
human.rdf", "Turtle");
```

# 数据集说明

1. 通过执行下列命令来获得所有顶点聚类后的分类和属性:

MATCH (n) RETURN labels(n) AS labels, keys(n) AS properties, COUNT( $^*$ ) AS total Order BY total DESC;



2. 通过执行下列命令来获得顶点和属性之间的关系类型:

MATCH (m)-[r]->(n) RETURN labels(m), type(r), labels(n), COUNT(\*) AS total Order BY total DESC;

